
# Escola Supercomputador SDUMONT

## Introdução E/S Paralela no SDUMONT
## Lustre

*André Ramos Carneiro (andrerc@lncc.br)*
*Bruno Alves Fagundes (brunoaf@lncc.br)*

# Lustre

LNCC
www.lncc.br
Laboratório Nacional de Computação Científica

Roteiro:

- O Sistema de Arquivos Lustre
- Arquitetura
- I/O + Stripe
- Lustre no SDumont
- Utilitário lfs
  - Configuração de Stripe
  - Comandos Básicos
- Melhores Práticas e Recomendações

# O Sistema de Arquivos Lustre



- Filesystem OpenSource
- Projetado para ser escalável
- Capaz de lidar com um grande volume de dados e um enorme número de arquivos
- Alta disponibilidade
- Coerência de dados e metadados
- Armazenamento Baseado em Objetos
- Filesystem ext4 (modificado) ou zfs
- Conformidade com o Padrão POSIX

# O Sistema de Arquivos Lustre



- Rede heterogênea de alto desempenho
  - InfiniBand, TCP (10GE e IpoIB), Myricom, Cray Seastar, Omni-Path
- Lista de Controle de Acesso (ACL), atributos estendidos
- Locks de arquivo e metadados, na granularidade de byte
- Striping
- MPI I/O – ADIO (Abstract-Device Interface for I/O)
- Escalável Crescimento da Capacidade
  - → Mais Servidores = Mais Armazenamento+Largura de Banda
- NFS e CIFS
- disaster/recovery
- Monitorador de desempenho

# Object Based Storage



## Object Based vs Block Based

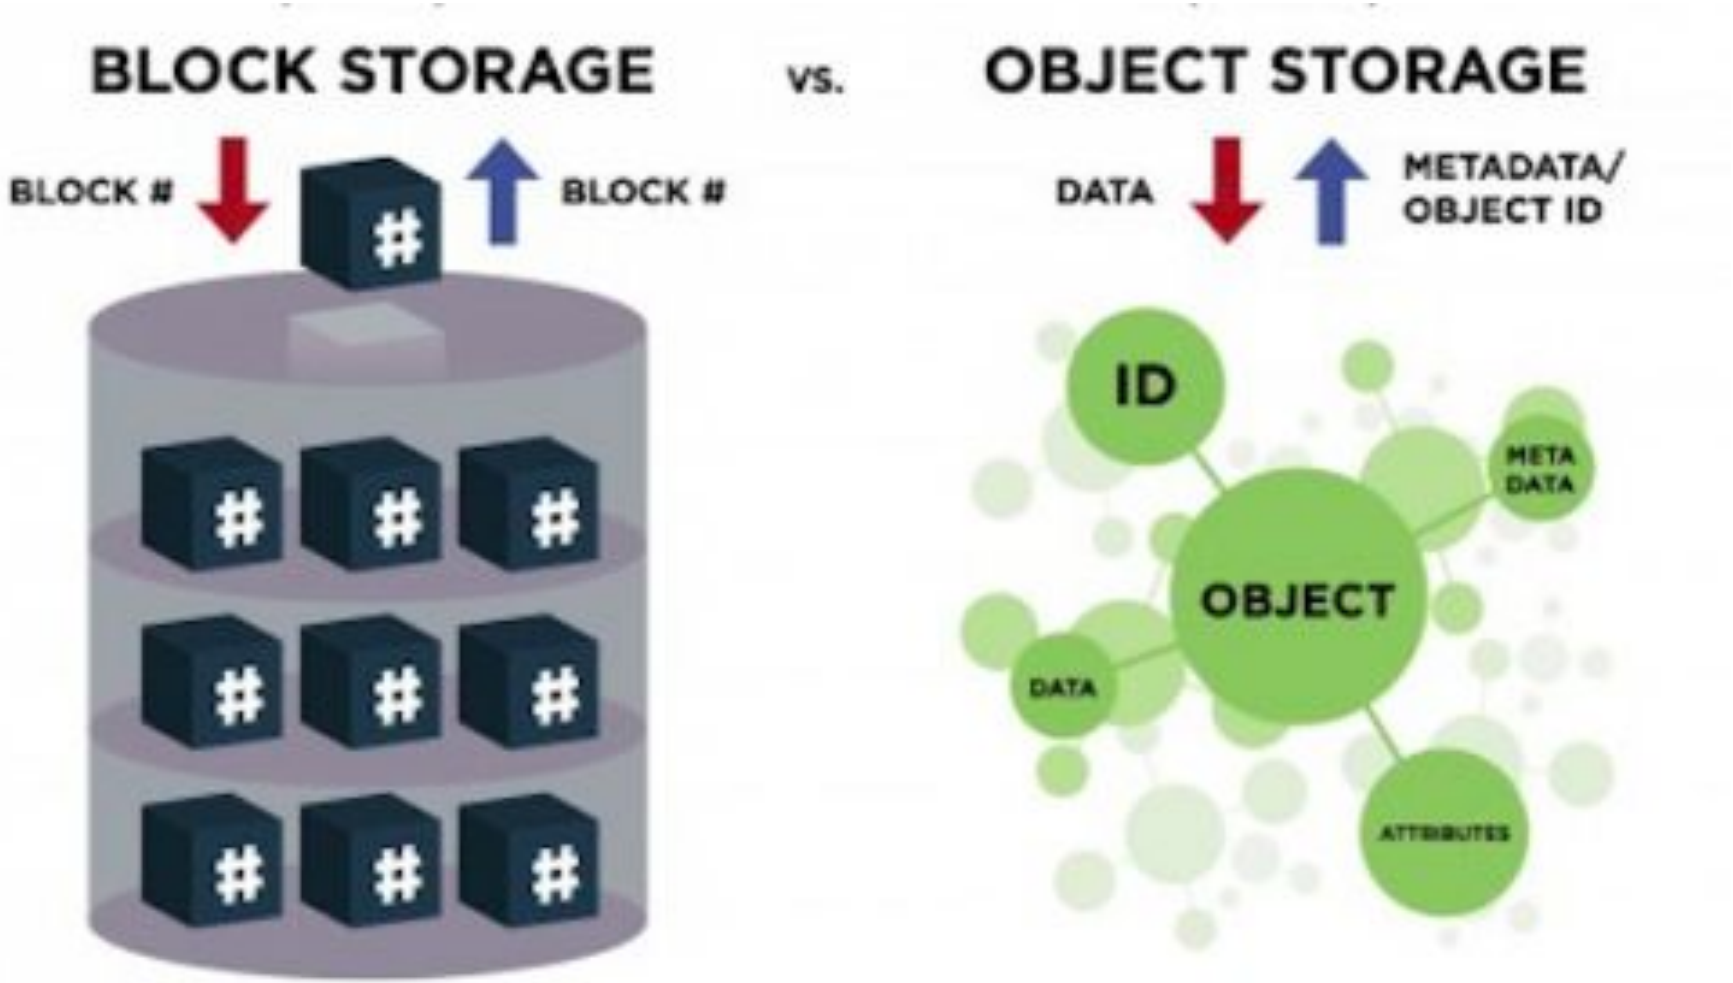

# Object Based

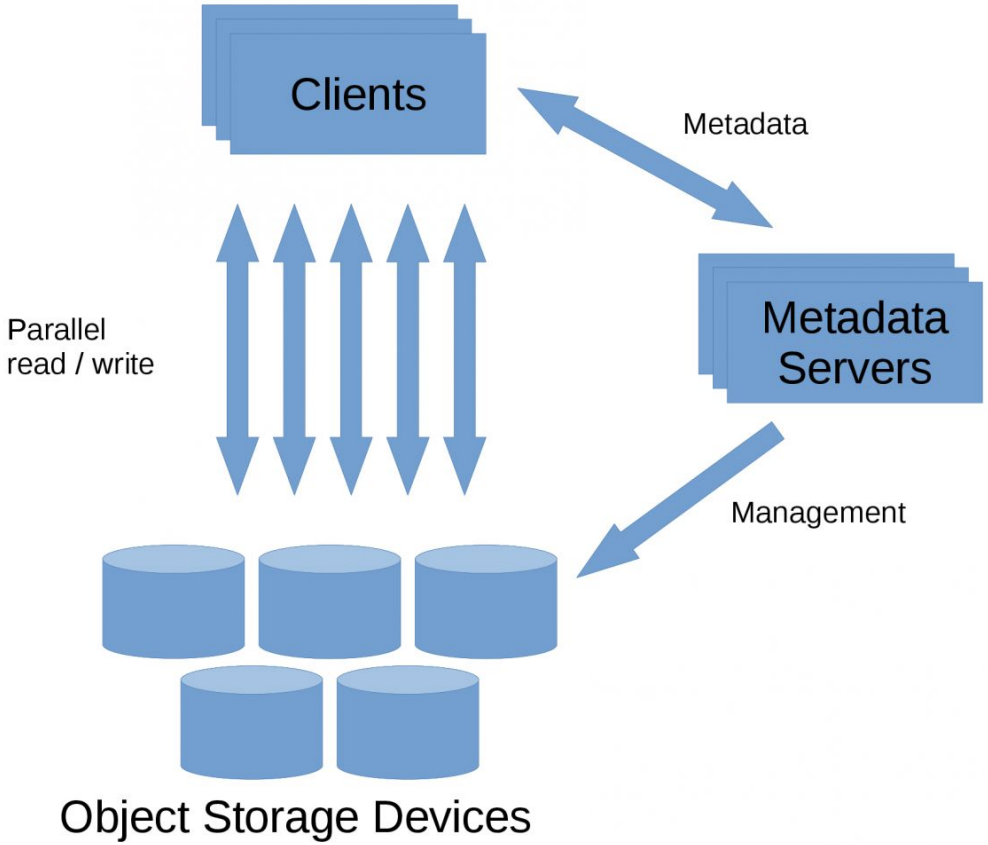

# Arquitetura

LNCC
www.lncc.br
Laboratório Nacional de Computação Científica

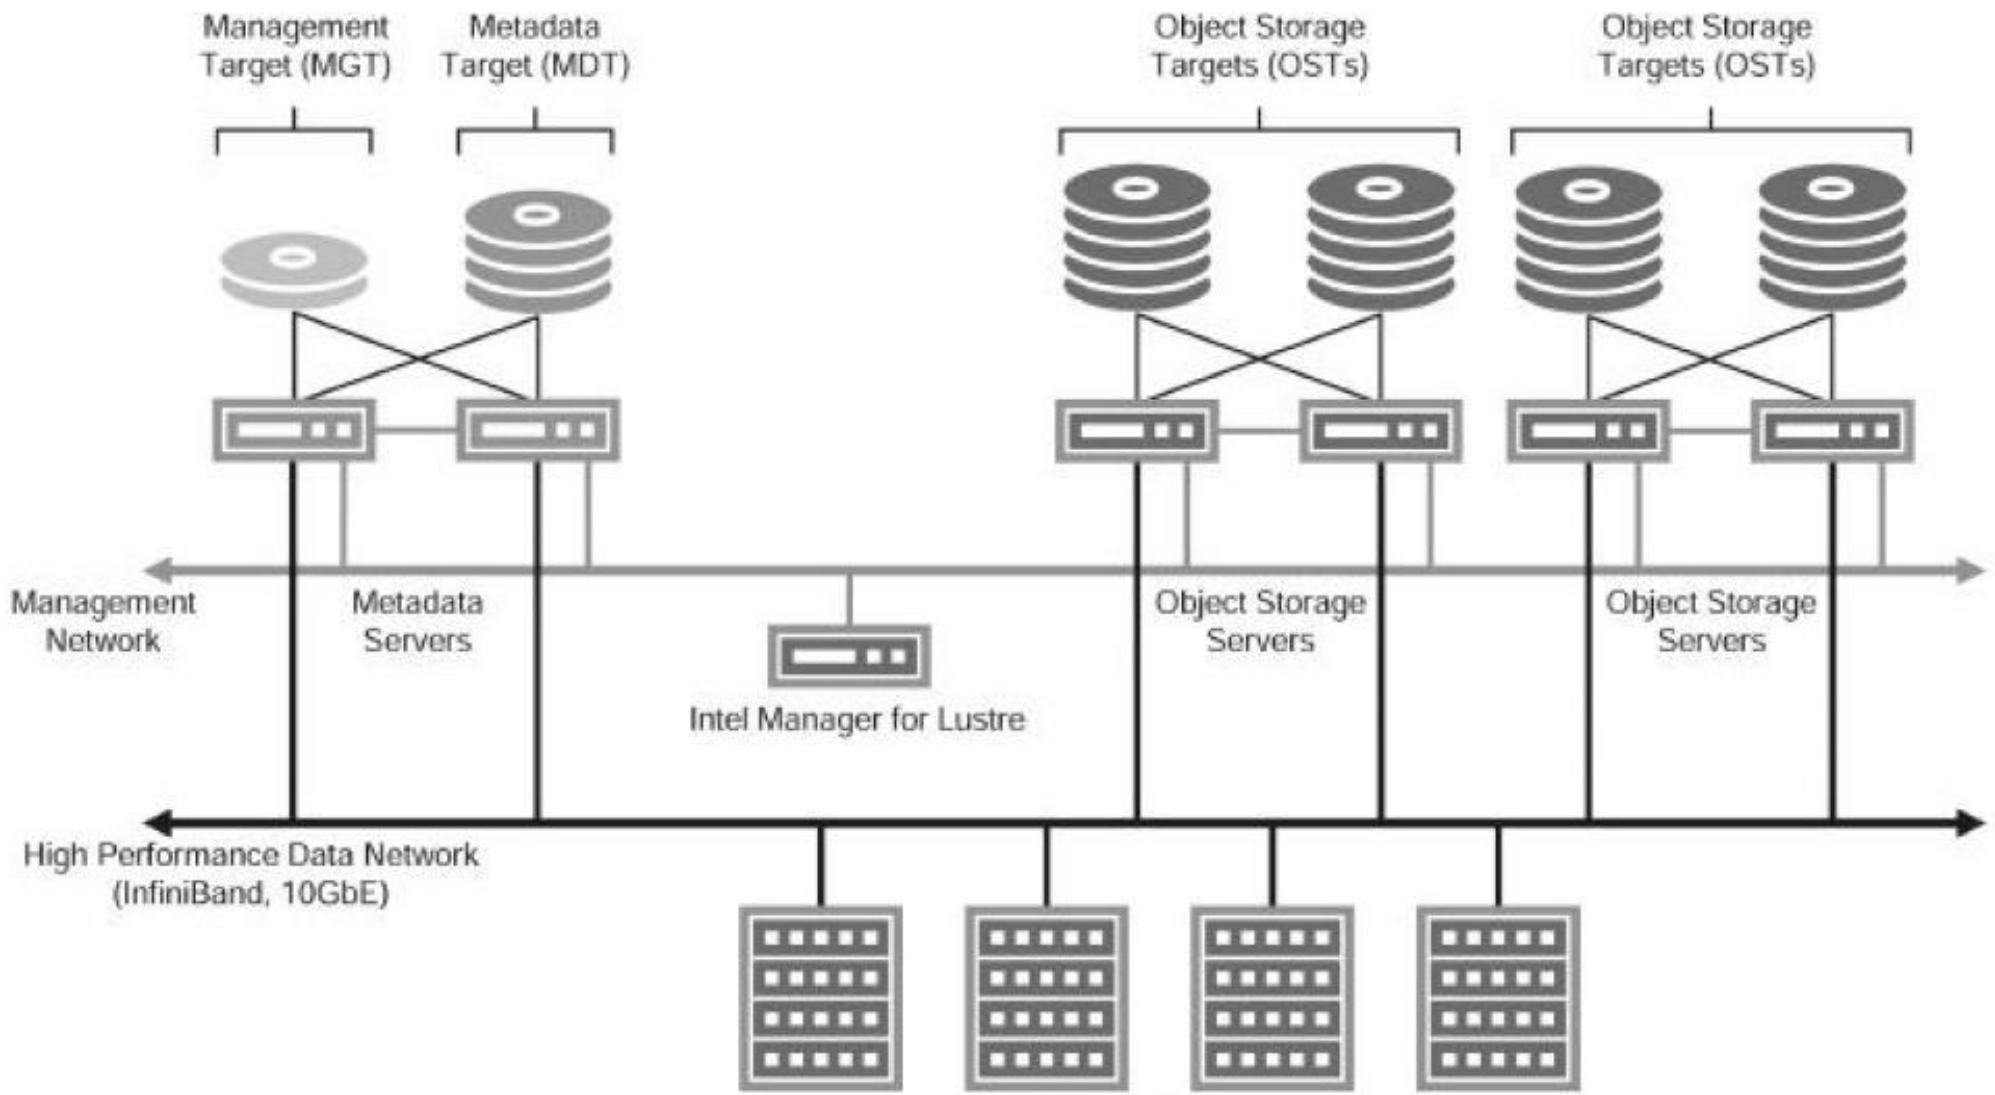

# Arquitetura



- MGS – **M**ana**g**ement **S**erver – Servidor de Gerenciamento
- MDS – **M**eta**d**ata **S**erver – Servidor de Metadados
- MDT – **M**eta**d**ata **T**arget – Onde os objetos de metadados são armazenados
- OSS – **O**bject **S**torage **S**erver – Servidor de Armazenamento de Objetos
- OST – **O**bject **S**torage **T**arget – Onde os objetos de dados são armazenedos
- Clientes Lustre
- Para cada Servidor (MGS, MDS e OSS) há um componente cliente correspondente
- LNET (ptlrpc)

# Arquitetura



- Objetos Lustre:
  - (1) objetos de dados: arrays de bytes para armazenar os dados dos arquivos
  - (2) objetos de índice: contêineres que armazenam pares de chave-valor – implementando a estrutura de diretórios POSIX
- Objetos implementados pelo Lustre OSD (object storage device)
  - ldiskfs (ext4) ou zfs
- Dispositivo de block (disco, lun) → 1 OSD → storage target → MDT ou OST

# Arquitetura



- storage target
  - MDTs – Metadata targets: Armazenam os metadados (como nomes de arquivos, diretórios, permissões de layout de arquivo)
  - OSTs – Object Targets: Armazenam os dados dos arquivos
- MDSs – Servidores de Metadados: Exportam os MDTs. Operações no namespace (como busca de arquivos, criação de arquivo, e manipulação de atributos de arquivo e diretório)
- OSSs – Servidores de Objetos: Exportam os OSTs. Fornecem serviço de I/O de arquivo, além de tratamento de requisições de rede para um ou mais OSTs locais.

# Arquitetura



- Comunicação entre clientes e servidores através do LNET
  - Abstração das redes físicas (IB / TCP/IP)
  - Troca de mensagens de RDMA
  - Lustre RPC (ptlrpc)

- LDLM – Lustre Distributed Lock Manager): serviço de lock fornecido pelos storage targets (MDT ou OST)
  - *Serializa* operações conflitantes
  - Garante coerência do cache distribuído

# Armazenamento e Operações de E/S



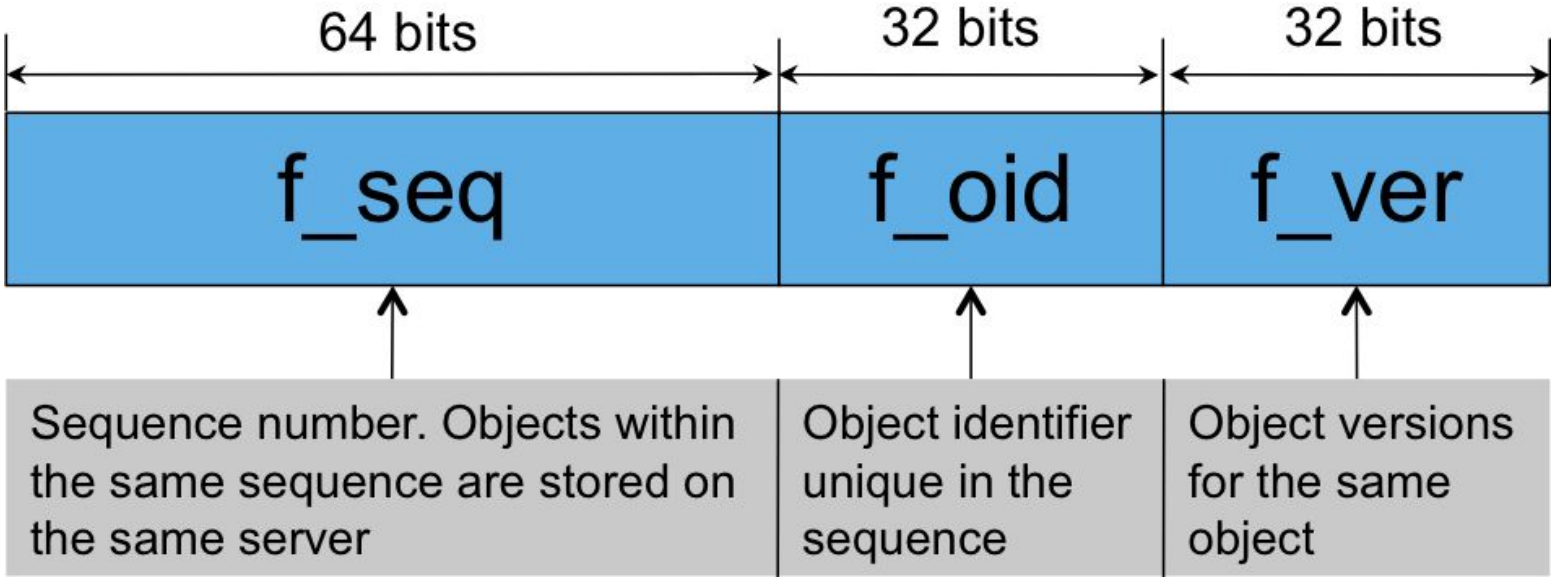


- FID – File Identifiers: Introduzido na versão 2.0. Substitui os números de inodes para identificar arquivos ou objetos de forma única
  - f_seq: 64 bits para localizar o storage target (MDT)
  - f_oid: Um ID de objeto (OID – Object ID) de 32 bits
  - f_ver: O número da versão em 32 bits (registra as alreações realizadas)

# Armazenamento e I/O no Lustre FS



- ***Layout EA***: Atributo estendido que armazena informação sobre onde os dados do arquivo estão localizados no(s) OST(s)
  - Armazenado no Objeto MDT, identificado pelo FID do arquivo.

- Se o arquivo é um arquivo regular, o objeto MDT possui um relacionamento que aponta de 1-para-N objeto(s) OST

- Se o objeto MDT apontar para mais do que um objeto → arquivo foi dividido em stripes, sendo cada objeto (stripe) armazenado em um OST diferente

# Armazenamento e I/O no Lustre FS



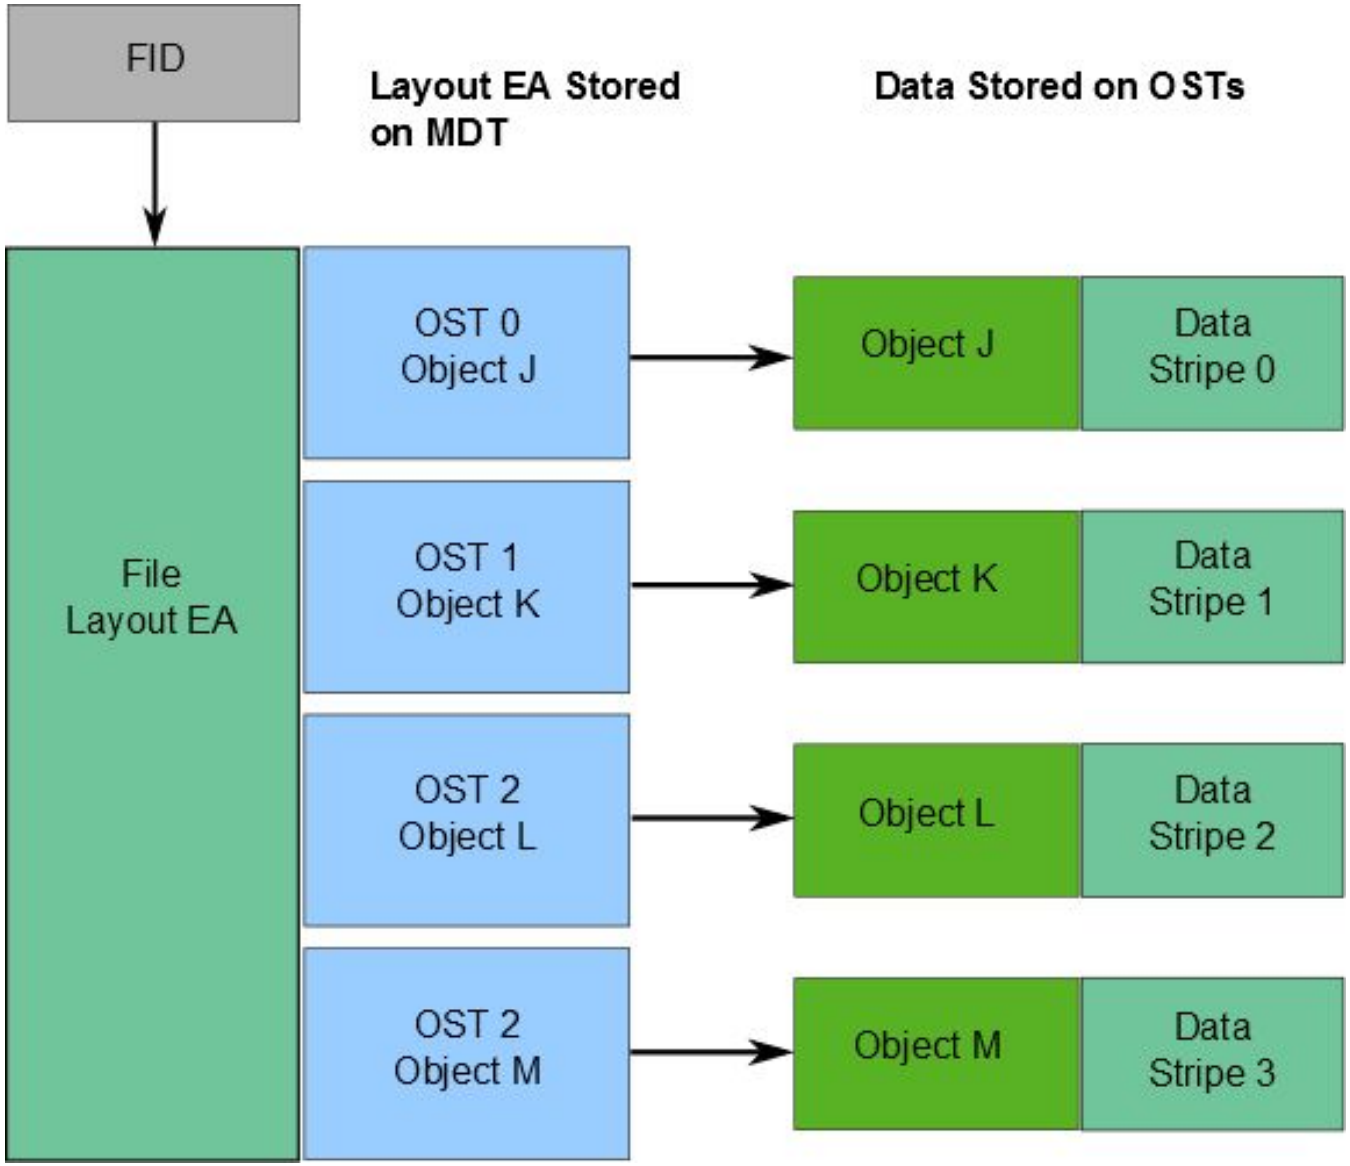

# Armazenamento e I/O no Lustre FS

LNCC
www.lncc.br
Laboratório Nacional de Computação Científica

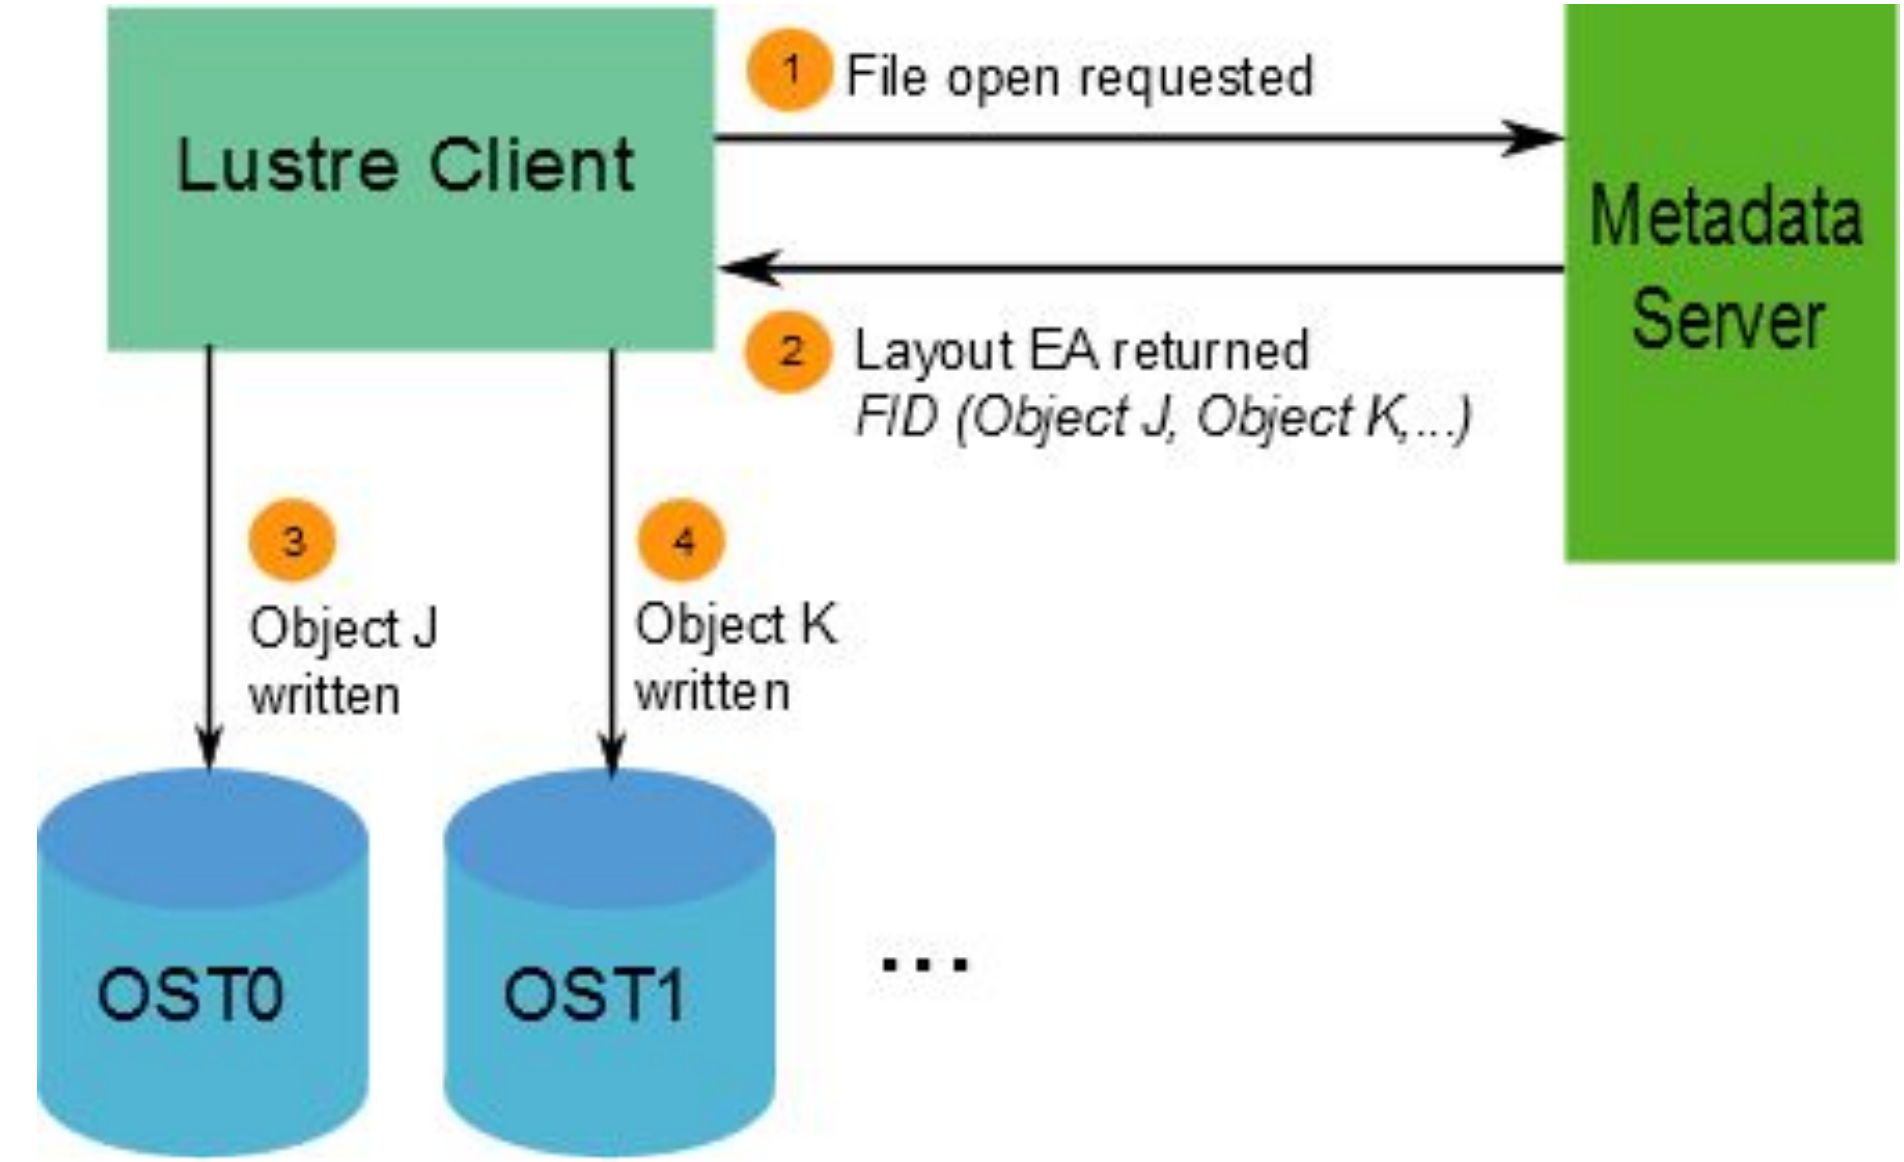

# Armazenamento e Striping



- Dividir arquivos em stripes (“faixas”) em um esquema RAID 0, sendo cada uma armazenada em objetos/OSTs diferentes

- Utilizado para melhorar o desempenho
  - Largura de banda agregada para um único arquivo excede a largura de banda de um único OST/OSS
  - OST não possui espaço suficiente para armazenar o arquivo inteiro

- `stripe_count`: determina em quantos pedaços (chunks)/objetos de dados um arquivo será dividido

- `stripe_size`: determina a quantidade de dados que será armazenada em cada pedaço/objeto

# Armazenamento e I/O no Lustre FS
## Striping

LNCC
www.lncc.br
Laboratório Nacional de Computação Científica

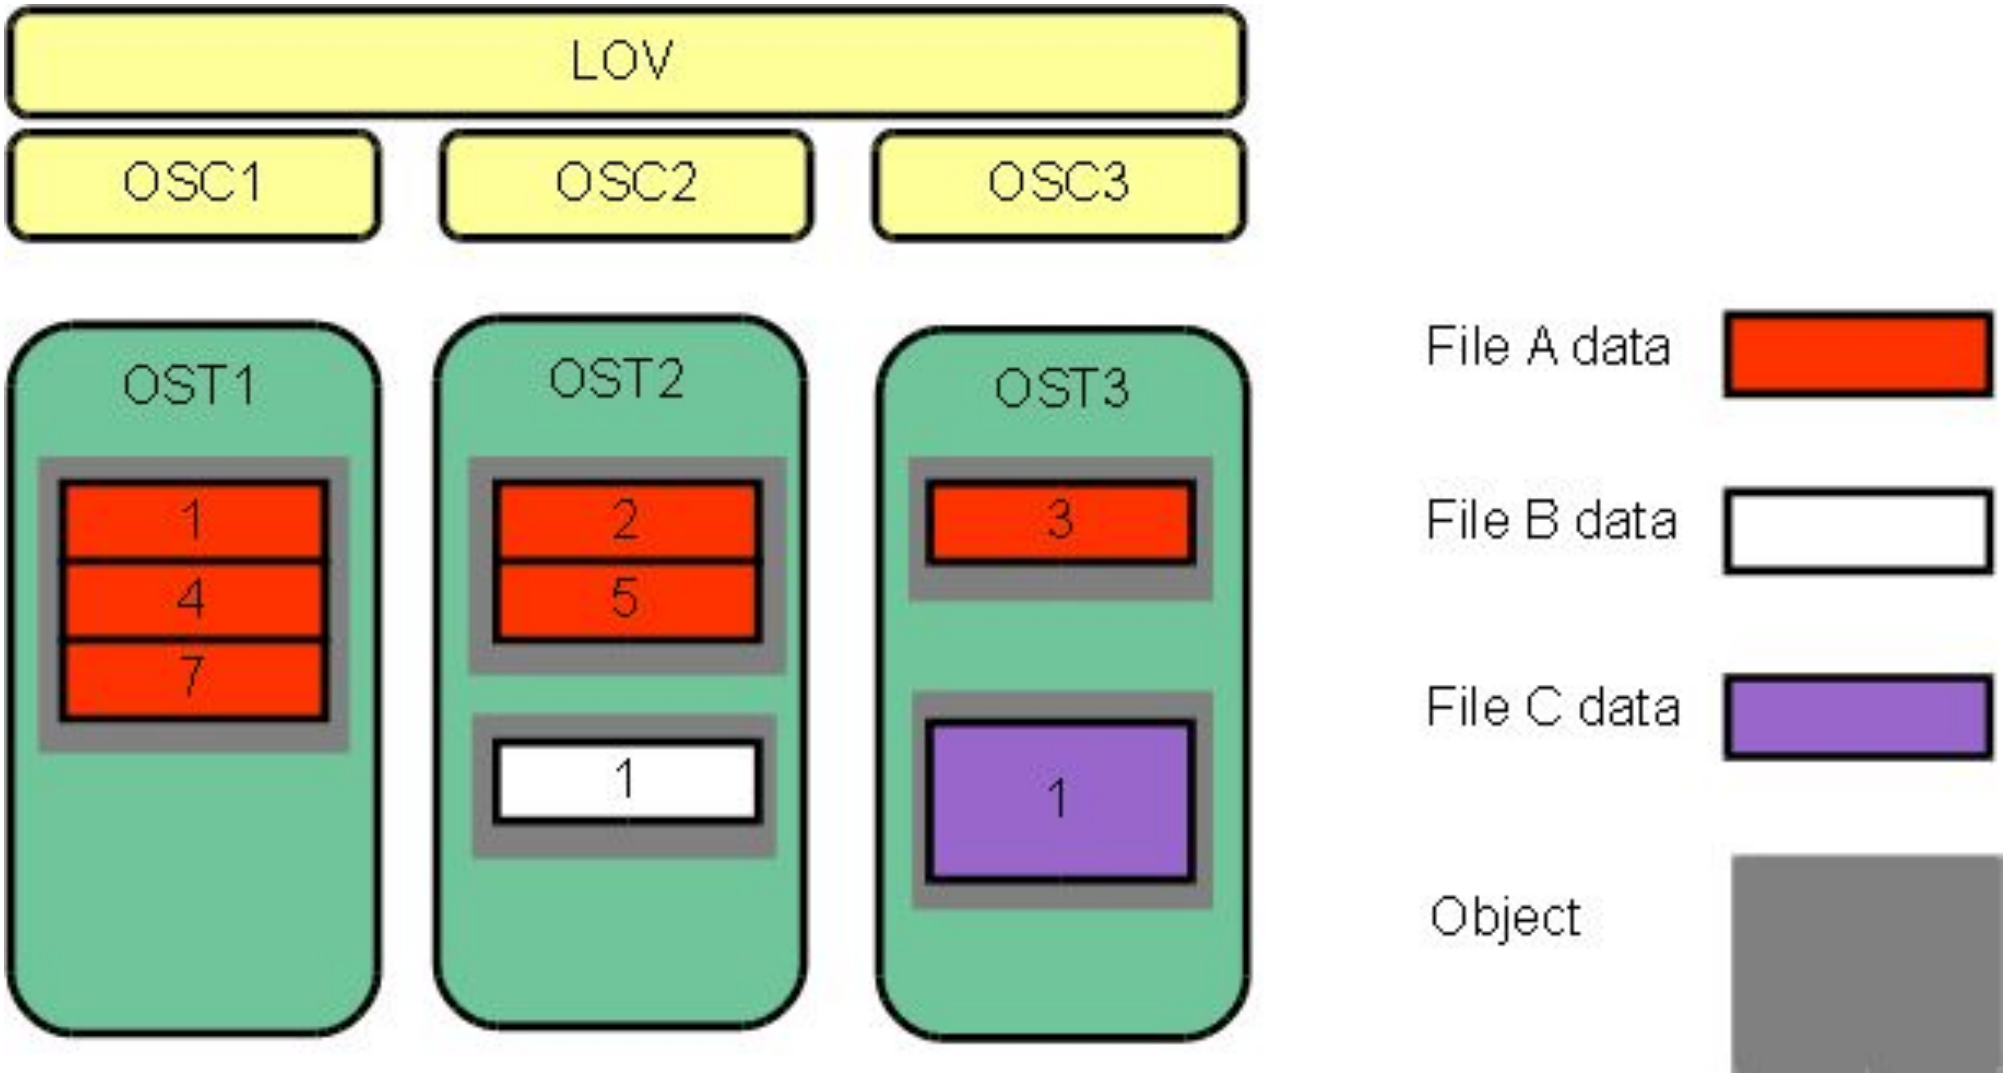

# Armazenamento e I/O no Lustre FS
## Striping



- O tamanho máximo do arquivo não é limitado pelo tamanho de um único target
- O valor **padrão** para o stripe_count é **1** e o máximo é 2000 (limitado pelo número de OSTs).
- O valor padrão para o stripe_size é **1MB** e o máximo é 16TB no *ldiskfs* e 256PB no *ZFS*
- O tamanho máximo do arquivo 32PB no *ldiskfs* e de 8EB no *ZFS*
- A largura de banda de I/O para acessar um único arquivo é a largura de banda agregada de I/O para os objetos do arquivo

# Lustre do SDUMONT

LNCC
www.lncc.br
Laboratório Nacional de Computação Científica

- Solução ClusterStor da Xyratex (Seagate -> Cray) - V 3.2
- 2 nós de Administração
- 2 nós MGS / MDS (Ativo/Ativo Alternados)
- 10 nós OSS (5 pares Ativo/Ativo)
- Utilizando interconexão Infiniband
  - 172.20.250.103@o2ib,172.20.250.104@o2ib:/cstor → /scratch
- Tamanho total do volume – 1.7 PB
- Versão do Lustre no Servidor: 2.11
- Versão do Lustre nos Clientes: 2.11

# lfs – Configurar o Striping



- **lfs** *setstripe* -S stripe_size -c stripe_count filename|dirname
- Exemplo – configura o layout para um diretório. Todos os arquivos que forem criados dentro do diretório possuirão o mesmo layout:
  - Arquivos existentes no diretório não terão seu layout alterado!

```
cd $SCRATCH
mkdir full_stripe
lfs setstripe -S 4m -c -1 full_stripe
##
mkdir single_stripe
lfs setstripe -S 1m -c 1 single_stripe
```

# lfs – Configurar o Striping



- **lfs** *getstripe* filename|dirname
- Exemplo – lista informações do diretório (único stripe):

```
cd $SCRATCH
lfs getstripe -d single_stripe
single_stripe
stripe_count:   1 stripe_size:    1048576 stripe_offset:  -1
```

# lfs – Configurar o Striping



- **lfs** *getstripe* filename|dirname
- Exemplo – cria um arquivo e lista suas informações (único stripe):

```
dd if=/dev/zero of=single_stripe/teste_single_stripe bs=1M
count=1k
lfs getstripe single_stripe/teste_single_stripe
single_stripe/teste_single_stripe
lmm_stripe_count:   1
lmm_stripe_size:    1048576
lmm_layout_gen:     0
lmm_stripe_offset:  3
obdidx       objid                objid          group
 3          1167913          0x11d229       0
```

# lfs – Configurar o Striping

LNCC
www.lncc.br
Laboratório Nacional de Computação Científica

- **lfs** *getstripe* filename|dirname
- Exemplo – lista informações do diretório (full stripe):

```
lfs getstripe -d full_stripe
full_stripe
stripe_count:   -1 stripe_size:    4194304 stripe_offset:  -1
```

# lfs – Configurar o Striping



- Exemplo – cria um arquivo e lista suas informações (full stripe):

```
dd if=/dev/zero of=full_stripe/teste_full_stripe bs=4M count=256
lfs getstripe full_stripe/teste_full_stripe
full_stripe/teste_full_stripe
lmm_stripe_count:   10
lmm_stripe_size:    4194304
lmm_layout_gen:     0
lmm_stripe_offset:  8
obdidx     objid     objid     group
     8        1167882        0x11d20a             0
     2        1167720        0x11d168             0
     9        1166249        0x11cba9             0
     1        1167274        0x11cfaa             0
     7        1165803        0x11c9eb             0
     5        1152459        0x1195cb             0
     3        1167915        0x11d22b             0
     6        1167210        0x11cf6a             0
     4        1166409        0x11cc49             0
     0        1167722        0x11d16a             0
```

# lfs – Alterar o layout do Striping

LNCC
www.lncc.br
Laboratório Nacional de Computação Científica

- **lfs** *migrate* -S stripe_size -c stripe_count filename|dirname
- Exemplo - Alterar o layout do arquivo para 4 stripe e 4MB

```
$ lfs getstripe single_stripe/teste_single_stripe
single_stripe/teste_single_stripe
lmm_stripe_count:   1
lmm_stripe_size:    1048576
...
      obdidx         objid         objid         group
           1         924972680       0x3721f688                  0

$ lfs migrate -S 4M -c 4 single_stripe/teste_single_stripe

$ lfs getstripe single_stripe/teste_single_stripe
single_stripe/teste_single_stripe
lmm_stripe_count:   4
lmm_stripe_size:    4194304
...
      obdidx         objid         objid         group
           1         924973004       0x3721f7cc                  0
           7         928675919       0x375a784f                  0
           5         911874379       0x365a194b                  0
           3         931125730       0x377fd9e2                  0
```

# lfs – Comandos Básicos



- `lfs df`: exibe a utilização do espaço no Lustre

```
$ lfs df -h
UUID                       bytes        Used   Available Use% Mounted on
cstor-MDT0000_UUID           2.8T      479.9G        2.3T  18% /scratch[MDT:0]
cstor-OST0000_UUID         168.0T       55.5T      110.8T  34% /scratch[OST:0]
cstor-OST0001_UUID         168.0T       50.4T      115.9T  31% /scratch[OST:1]
...
cstor-OST0008_UUID         168.0T       55.5T      110.9T  34% /scratch[OST:8]
cstor-OST0009_UUID         168.0T       50.5T      115.8T  31% /scratch[OST:9]

filesystem_summary:          1.6P      522.4T        1.1P  32% /scratch
```

# lfs – Comandos Básicos

LNCC
www.lncc.br
Laboratório Nacional de Computação Científica

- `lfs find`: Realiza busca no Lustre

```
lfs find . -atime -1 -name '*.f90'
```

- `lfs quota -u|-g <filesystem>`: Obtém a quota → Utilização do espaço no Lustre
  - `lfs quota -g PROJETO /scratch/PROJETO`
- `lfs cp`: Realiza cópias de arquivos e diretórios no Luster (descontinuado na 2.11)
- `lfs ls`: Lista informações sobre arquivos e diretórios (descontinuado na 2.11)
- `lfs path2fid`: Exibe o FID para um determinado arquivo ou diretório:
  - $ lfs path2fid full_stripe/teste_full_stripe single_stripe/teste_single_stripe

    full_stripe/teste_full_stripe: [0x240004762:0x8def:0x0]

    single_stripe/teste_single_stripe: [0x240004762:0x8dec:0x0]
- Para uma lista completa dos comandos: `lfs help`
- Para informações específicas de um comando: `lfs help "comando"`

# Melhores Práticas - striping



- Algumas razões para utilizar o striping incluem:
  - Fornece alta largura de banda para o acesso → quanto mais OSTs = mais vias para acessar o arquivo
  - Fornecendo espaço para arquivos muito grandes → quanto mais OSTs = mais espaço agregado para armazenamento

- Algumas razões para minimizar ou evitar o striping:
  - Aumento do overhead → Aumenta o número de locks e pode gerar “Disputas por I/O - Servidor”
  - Aumento do risco → Em caso de falha de um OSS/OST, parte do arquivo se perde
    - Todos arquivos (stripe = all) x Alguns arquivos (stripe = single)

# Melhores Práticas - striping



- O stripe_size não possui efeito em um arquivo que possui stripe_count igual a um
- O tamanho do stripe deve ser um múltiplo do tamanho da página (64KB)
- O menor tamanho recomendado de stripe é 512KB
- Um bom tamanho de stripe para I/O sequencial utilizando redes de alta velocidade é entre 1MB e 4MB
- O tamanho máximo para o stripe é de 4GB
- stripe_count = total de nós ou múltiplo do número de nós (16 nós -> 8 stripe_count)
- Escolher um padrão de stripe que leve em consideração os padrões de escrita da aplicação, evitando acesso desalinhado ao filesystem e contenção

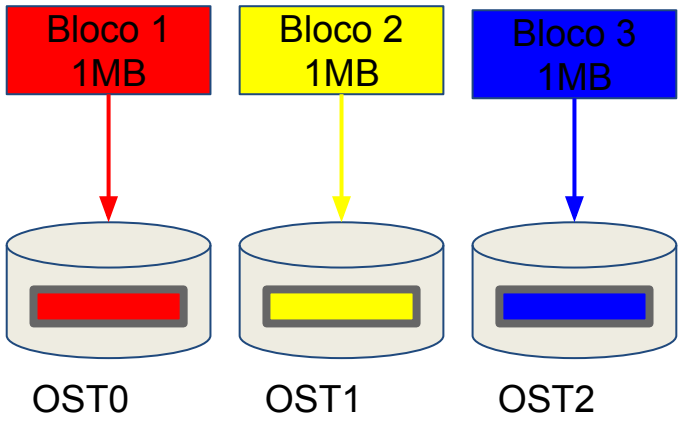


1MB Stripe Size
3 Stripe Count

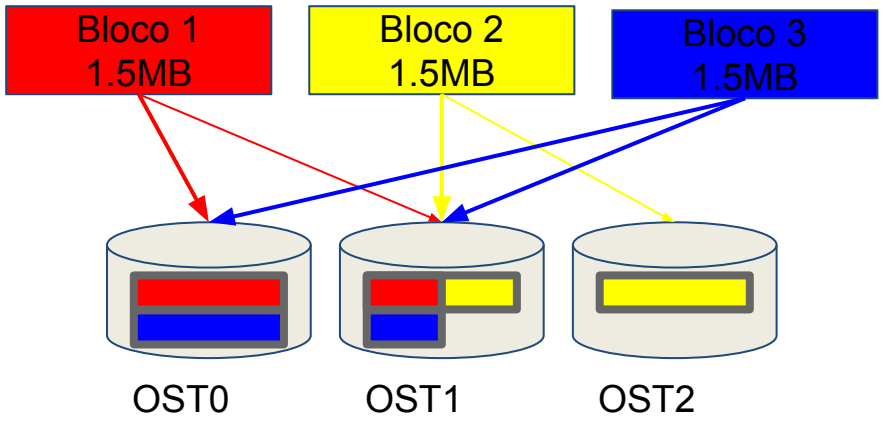

# Melhores Práticas



- Evite utilizar o comando “ls -l” (especialmente em diretórios)
  - “ls” se deseja verificar que um arquivo existe.
  - “ls -l nome-no-arquivo” se deseja obter maiores informações de um arquivo específico.
- Evite ter um grande número de arquivos em um único diretório
- Evite acessar pequenos arquivos no Lustre (< 10MB)
- Utilize um “Stripe count” igual a 1 para diretórios com muitos arquivos pequenos
- Mantenha o código fonte no HOMEDIR
  - Compilar dentro do HOME → Mover para o SCRATCH
- Aumente o “stripe count” para o acesso paralelo ao mesmo arquivo
- Limite o Número de processos realizando E/S Paralela
- Experimente diferentes valores para o stripe count/size para as operações de escritas coletivas do MPI
  - `MPI_File_write_all / MPI_File_write_at_all / MPI_File_write_ordered`

# Dúvidas?